

Team



Carole Mattmann



Luca Casuscelli



Jonas Zürcher



Silvan Leibacher

Agenda

- 1. Fragestellung, Vorgehen und Tools
- 2. Prozessschritte CIP
- 3. Beantwortung Fragestellung
- 4. Schlusswort, Diskussion, Ausblick

\equiv

Fragestellungen

- 1. Welches Masterstudienangebot für Data Science existiert in Europa?
- 2. Welche Universität in Asien, hat das beste internationale Ranking und bietet einen Studiengang in Data Science an?
- 3. Wie verändert sich das Studienangebot im Bereich Data Science in der Region Amerika im Verlauf der Zeit?

Vorgehen

- 1. Crawlen der Daten
- 2. Bereinigung und Transformation mit Pandas
- 3. Vereinigung der Daten in Tableau Prep zu einem Datenset
- 4. Import des Datensets in eine SQL-Datenbank



Collection und Extraction

mit Python

Es bestehen zwei vom Aufbau her fast identische Crawler. Die beiden Webseiten der Studiengänge stammen vom selben Anbieter und sind genau gleich aufgebaut.

- Data-Crawling über alle Data Science Studiengänge aus zwei Quellen: https://www.bachelorstudies.com/Data-Science/, https://www.masterstudies.com/Data-Science/
- Data-Crawling über die Rankings aller Hochschulen: http://www.webometrics.info/en/world

Data Cleaning

mit Pandas (Python)

- Die Anwendung von Pandas und damit der erste Teil der Daten Bereinigung erfolgt bereits in den Crawler Skripten.
- Der Bereinigungs-Prozess wurde in der Funktion "cleanse_data(dataframe)" definiert. Dieser wurde nur bei den Studiengangs-Daten angewendet, damit mehr Bereinigungsschritte mit Tableau Prep übrigbleiben.

Cleaning, Integration & Transformation

In Tableau Prep



Cleaning, Integration & Transformation

Von drei csv-Dateien in Tableau Prep

Grobbereinigung der "school ranking"-Daten

- Transformation Abschlusstyp, Dauer, Schulstart
- Vereinigung & Verknüpfung der Datensets, redundante Spalten löschen
- Kopfzeile & Spaltenreihenfolge anpassen

- Transformation Lokalisierung & Sprache
- Export der Datei als csv und tde

Transfer & Import auf die Datenbank

Microsoft SQL Server 2017 + Microsoft SQL Server Management Studio

- 1 Datenbank erstellen
- Datenset importieren
- 3 Kontrolle des Imports



Fragestellung 1: Welches Masterstudienangebot für Data Science existiert in Europa? (Stand: 20.03.2020)

- In Tableau wurden die Daten gefiltert, dass nur noch Hochschulen von Europa mit einem Master Programm angezeigt werden.
- 102 Hochschulen bieten Data Science Studiengänge auf Stufe Master an.
- Einige Hochschulen bieten mehrere Studiengänge an.
- Die Hochschule Luzern fehlt leider in der Liste.

Fragestellung 2: Welche Universität in Asien, hat das beste internationale Ranking und bietet einen Studiengang in Data Science an? (Stand: 20.03.2020)

- In Tableau wurden die Daten gefiltert, dass nur noch Hochschulen von Asien mit einem Data Science Programm und einem vorhandenen Hochschul-Ranking angezeigt werden
- Die City University of Hong Kong das beste Ranking mit dem Gesamt-Rang von 186.
- Die City University of Hong Kong bietet drei Studiengänge an.

Fragestellung 3: Wie verändert sich das Studienangebot im Bereich Data Science in der Region Amerika im Verlauf der Zeit? (Zeitintervall: 20.03.2020-09.04.2020)

- Die zwei Übersichtsdatensets von den beiden Zeitpunkten werden verwendet.
- Ein neues Datensets wird im Tableau Prep erstellt.
- Das neue Datenset beinhaltet nur Zugänge und Abgänge bei den Studiengängen.

Fragestellung 3: Wie verändert sich das Studienangebot im Bereich Data Science in der Region Amerika im Verlauf der Zeit? (Zeitintervall: 20.03.2020-09.04.2020)

- Das Studienangebot hat sich für den Kontinent Nordamerika im Zeitabschnitt nur leicht verändert.
- Hinzugekommen ist der Studiengang "MS in Health Data Analytics (On-Campus)" der University of Louisville.
- Weggefallen ist der Studiengang "Master of Science in Computer Science Data Analytics» der Nova Southestern University.



=

Diskussion

- Nur die gecrawlten Daten der Studiengänge wurden mit Pandas gereinigt. Es wäre sinnvoll diese bei einer Weiterverfolgung des Projekts bei allen gecrawlten Daten durchzuführen.
- Problem könnte aber in Zukunft entstehen, wenn neue Hochschulen Data Science Studiengänge einführen (v.a. Verknüpfungsschritt im Tableau Prep). Die Datensets der Studiengänge und der Rankings werden über den Hochschulnamen verknüpft.
- Die Namen derselben Hochschulen unterscheiden sich leider in nicht reproduzierbarer Weise und führt zu Problemen im Matching. → Für eine 100 % Übereinstimmung müsste man alle Datensets mittels einer klar zuweisbaren ID oder örtlichen Adresse zur Verfügung haben.

=

Ausblick

- Der nächste Schritt in diesem Projekt wäre die Verknüpfung der verschiedenen Datensets zu optimieren.
- Das Übersichtsdatenset könnte zur Entwicklung einer Applikation verwendet werden.
- Die Applikation könnte bei Studienplanung, Vergleichen von Partneruniversitäten für ein Auslandsemester helfen oder auch als Führungsinstrument für die Studiengangsleitungen dienen.

